

# Programación 2

## TADs Colecciones: Conjuntos, Diccionarios, Multiconjuntos y Tablas (*Mappings*)

Implementaciones simples y  
avanzadas

## El TAD SET (Conjunto)

En el diseño de algoritmos, la noción de **conjunto** es usada como base para la formulación de tipos de datos abstractos muy importantes.

Un **conjunto** es una colección de elementos (o miembros), los que a su vez pueden ellos mismos ser conjuntos o si no elementos primitivos, llamados también átomos.

Todos los elementos de un conjunto son distintos, lo que implica que un conjunto no puede contener dos copias del mismo elemento.

# EL TAD SET

Una notación usual para exhibir un conjunto es listar sus elementos de la siguiente forma:  $\{1, 4\}$ , que denota al conjunto cuyos elementos son los naturales 1 y 4. Es importante destacar que los conjuntos no son listas, el orden en que los elementos de un conjunto son listados no es relevante ( $\{4, 1\}$ , y también  $\{1, 4, 1\}$  denotan al mismo conjunto).

**Lists** (orden y repetición posible de elementos)

**MultiSets** (no hay orden pero si se permite repet.)

**Sets** (no hay orden ni repetición de elementos)

# EL TAD SET

La relación fundamental en teoría de conjuntos es la de pertenencia, la que usualmente se denota con el símbolo  $\in$ . Es decir,  $a \in A$  significa que  $a$  es un elemento del conjunto  $A$ . El elemento  $a$  puede ser un elemento atómico u otro conjunto, pero  $A$  tiene que ser un conjunto.

Un conjunto particular es el conjunto vacío, usualmente denotado  $\emptyset$ , que no contiene elementos.

Las operaciones básicas sobre conjuntos son unión, intersección y diferencia.

## El TAD SET

- **Vacio** c: construye el conjunto c vacío;
- **Insertar x c: agrega x a c, si no estaba el elemento en el conjunto;**
- **EsVacio** c: retorna true si y sólo si el conjunto c está vacío;
- **Pertenece** x c: retorna true si y sólo si x está en c;
- **Borrar** x c: elimina a x del conjunto c, si estaba;
- **Destruir** c: destruye el conjunto c, liberando su memoria;
- **Operaciones para la unión, intersección y diferencia de conjuntos, entre otras.**

# Especificación del TAD SET

Otras operaciones adicionales que suelen considerarse para conjuntos son, por ejemplo, las siguientes:

- **Borrar**: dado un elemento lo elimina del conjunto, si es éste pertenece al mismo. También **Borrar\_min** y **Borrar\_max** (borran el mínimo y el máximo elem).
- **Min (Max)**: devuelve el elemento menor (mayor) del conjunto. Pre-condición: el conjunto es no vacío. Esta operación requiere un orden lineal sobre los elementos (o sobre sus claves).
- **Igual**: dado un conjunto, devuelve true si y sólo si el conjunto parámetro es igual al cual se le aplica el método. La igualdad es una operación útil y necesaria para la mayoría de los TADs.
- **Inclusiones, Cardinalidad, ...**

# Implementación del TAD SET

Algunos lenguajes de programación permiten una implementación de este tipo abstracto, con ciertas restricciones, de forma directa.

Por ejemplo, Modula-2 y Pascal. En estos lenguajes, el constructor de tipos SET OF < tipo-base> permite definir el tipo de todos los posibles conjuntos de elementos de tipo <tipo-base>.

- <tipo-base> debe ser un ordinal.

C y C++ no proveen implementaciones primitivas de este TAD.

# Implementaciones del TAD SET

A continuación veremos el TAD Diccionario y analizaremos implementaciones de éstos que son válidas para el TAD Set:

- usando **listas encadenadas** (ordenadas o no);
- por medio de un **arreglo de booleanos (o de bits)**;
- mediante **arreglos con tope**;
- a través de árboles ordenados (**ABBs**, **AVLs**);
- con **tablas de hash**.



# El TAD Diccionario

Hay dos TADs especialmente utilizados, basados en el modelo de conjuntos:

Los **diccionarios** y las **colas de prioridad**.

Este último será estudiado en el próximo módulo del curso. Ahora veremos diccionarios.

Cuando se usa un conjunto en el diseño de un algoritmo podría no ser necesario contar con operaciones de unión o intersección o diferencia.

# El TAD Diccionario

A menudo lo que se necesita es simplemente manipular un conjunto de objetos al que periódicamente se le agregan o quitan elementos. También es usual que uno desee verificar si un determinado elemento forma parte o no del conjunto.

Un TAD Set con las operaciones **Vacio**, **Insertar**, **EsVacio**, **Borrar** y **Pertenece** recibe el nombre de **diccionario**.

Una **cola de prioridad** es esencialmente un TAD Set con las operaciones **Vacio**, **Insertar**, **EsVacio**, **Borrar\_Min** y **Min** (**Borrar\_Max** y **Max**).

## El TAD Diccionario

- **Vacio** d: construye el diccionario (conjunto) vacío
- **Insertar x d: agrega x a d, si no estaba el elemento en el diccionario**
- **EsVacio** d: retorna true si y sólo si el diccionario d está vacío
- **Pertenece** x d: retorna true si y sólo si x está en d
- **Borrar** x d: elimina a x del diccionario d, si estaba
- **Destruir** d: destruye el diccionario d, liberando su memoria.

Ejercicio: Especificar el TAD Diccionario en C++.

# Implementación del TAD Diccionario

Existen distintas posibles implementaciones de este tipo abstracto.

Una primera posibilidad es usando **listas encadenadas** (**ordenadas o no**)

**-memoria dinámica-**

Otra posible implementación de un diccionario es por medio de un **arreglo de booleanos**. Este enfoque requiere que:


- los elementos del tipo base pertenezcan al subrango  $0..N$ , para algún natural  $N$ , o
- que pueda definirse una correspondencia uno a uno entre el tipo base y el anterior subrango de naturales.

# Implementación del TAD Diccionario

Una tercer posible implementación es usar un **arreglo con tope**. Este enfoque garantiza una representación correcta siempre y cuando el tamaño del diccionario no supere el largo del arreglo.

adicionalmente, una frecuentemente usada implementación es mediante **ABB** (o **AVL**). Este enfoque permite una eficiente definición de las operaciones y utilización del espacio de memoria.

# Implementación de Diccionarios y Conjuntos con arreglos de booleanos




$x$  pertenece al conjunto (diccionario)  $\Leftrightarrow A[x]=1$

- Las operaciones Insertar, Borrar y Pertenece se pueden implementar mediante una referencia directa al elemento (tiempo constante,  $O(1)$ ).
- ¿ Vacio y EsVacio ?
- ¿ Qué incluye la representación del TAD para arreglos de booleanos ? Esto es, ¿ Cuáles son los campos del struct para esta representación ?

# Implementación de Diccionarios y Conjuntos con arreglos de booleanos

- Para Sets, las operaciones **Union**, **InterSec** y **Diferencia** se pueden implementar en un tiempo proporcional al tamaño del conjunto universal.



Unión / Intersección / Diferencia

# Implementación de Diccionarios y Conjuntos con arreglos de booleanos

- Esta implementación requiere considerar un conjunto universal finito.

Los conjuntos (o diccionarios) son subconjuntos de este conjunto universal.

Naturalmente esta implementación se adecua a una versión acotada de Diccionarios y Conjuntos.



# Implementación de Diccionarios y Conjuntos con arreglos de booleanos

- Es necesario establecer una **correspondencia** de los elementos del dominio con un rango  $0..N$ , para un determinado número  $N$ . Ejemplos:
  - número de estudiante (en la facultad)
  - número de curso (en el plan de estudios)
  - número de empleado (en una empresa)
- Discutir los **algoritmos** para las operaciones de Conjuntos (en general) y Diccionario. Analizar el tiempo de ejecución de las operaciones.  
¿Qué ocurre con el espacio de almacenamiento?


# Implementación de Diccionarios y Conjuntos con arreglos de booleanos

¿Qué ocurre con el espacio de almacenamiento?


¿Se reserva la memoria mínima necesaria?

Pensar por ejemplo en inscripciones de estudiantes a cursos (matriz) ¿Hay más 0's que 1's?

Nro. curso



Nro estud.



0	0	0	1	0	1	...	...	...	0
0	0	...	...	...	1/0	0	...	...	...

# Implementación de Diccionarios y Conjuntos con listas encadenadas



- Esta implementación consiste en representar a los conjuntos (diccionarios) por medio de **listas encadenadas**, cuyos elementos son los miembros del conjunto (diccionario).
- A diferencia de la implementación con arreglos de booleanos, la representación mediante listas utiliza un **espacio proporcional al tamaño** del conjunto (diccionario) representado, y no al del conjunto universal.

# Implementación de Diccionarios y Conjuntos con listas encadenadas

- Más aún, ésta representación es más general, puesto que puede manejar conjuntos (diccionarios) que no necesitan ser subconjuntos de algún conjunto universal finito.


Esta implementación se adecua bien a una versión NO acotada de Diccionarios y Conjuntos.

- Las listas pueden ser ordenadas o no.  
El tiempo de ejecución de las operaciones cambia según esta elección.

Por ejemplo, para Sets, la intersección, la unión y la diferencia sobre listas no ordenadas requieren...


# Implementación de Diccionarios y Conjuntos con listas encadenadas

- Las operaciones Insertar, Suprimir y Pertenece para listas ordenadas y no ordenadas requieren en el peor caso  $O(n)$ , con  $n$  el tamaño del conjunto (diccionario). Y ¿en el caso promedio?



# Implementación de Diccionarios y Conjuntos con listas encadenadas

- Para Sets, la intersección, la unión y la diferencia sobre listas no ordenadas de longitudes  $n$  y  $m$  es  $O(n*m)$  y, sobre listas ordenadas puede implementarse en  $O(n+m)$ .



- No ordenadas
  - $11 = [2,7,3,1,9,18,4]$ ;  $12 = [8,1,10,3,7,4,99,6,13]$
  - $11 \cap 12 = [...]$
- Ordenadas
  - $11 = [2,3,7,9,18]$ ;  $12 = [1,3,4,7,18,99]$
  - $11 \cap 12 = [...]$

# Implementación de Diccionarios y Conjuntos con listas encadenadas

¿Es posible hacer **búsqueda binaria** (por bipartición) sobre listas encadenadas ordenadas, de manera de garantizar  $O(\log(n))$ ?

# Implementación de Diccionarios y Conjuntos con listas encadenadas

- Para las operaciones Min, Max, Borrar\_Min y Borrar\_Max, ¿es igualmente eficiente usar listas ordenadas o no ordenadas?
- Para implementar diccionarios, conjuntos o colas de prioridad con listas, ¿qué debe incluir la representación del TAD?

Ejercicio: Desarrollar algoritmos para los TADs Diccionario, Conjunto y Cola de prioridad, luego de escribir sus especificaciones. Analizar luego sus órdenes de tiempo de ejecución en el peor caso para las implementaciones analizadas previamente.



# Implementación de Diccionarios mediante arreglos con tope



- Esta realización sólo es factible si se puede suponer que los conjuntos nunca serán más grandes que la longitud del arreglo en uso. Naturalmente esta implementación se adecua a una versión acotada de Diccionarios y Conjuntos.
- Tiene la ventaja de la sencillez sobre la representación con listas encadenadas.


# Implementación de Diccionarios mediante arreglos con tope

- Las desventajas de este tipo de representación, al igual que cuando discutimos el TAD Lista, son
  - (1) el diccionario no puede crecer arbitrariamente,
  - (2) la operación de borrado es dificultosa y
  - (3) el espacio de almacenamiento es ineficientemente utilizado.

# Implementación de Diccionarios con ABB

- La realización de diccionarios mediante ABB requiere que los elementos (o su campos claves) permitan un orden lineal.


Esta implementación se adecua a una versión NO acotada de Diccionarios y Conjuntos.



Diccionario


{ 4, 5, 11, 17, 8, 18, 12 }

Notar que para un conjunto dado existen múltiples ABBs posibles. Por ejemplo {1, 2, 3}:



# Implementación de Diccionarios con ABB

- La implementación de las operaciones de Diccionarios: **Vacio**, **EsVacio**, **Insertar**, **Pertenece y Borrar**, corresponden a las operaciones de ABB: **Vacio**, **EsVacio**, **Insertar**, **Buscar** y **Borrar**, respectivamente.
- Si se piensa en Conjuntos, ¿cómo serían las operaciones de unión, intersección y diferencia con ABB?; ¿cuál sería la eficiencia de estas operaciones?





# Implementación de Diccionarios con ABB

- Si se piensa en Colas de Prioridad, ¿cómo serían las operaciones Min / BorrarMin con ABB?; ¿cuál sería la eficiencia de estas operaciones?
- La longitud de un camino promedio de la raíz de un ABB a una hoja es  $O(\log(n))$ . Luego, las operaciones de diccionarios sobre ABB requieren  $O(\log(n))$  en el caso promedio.
- No obstante, estas operaciones requieren  $O(n)$  en el peor caso: las secuencias de supresiones e inserciones pueden transformar un árbol en el árbol degenerado correspondiente a una lista.


# Implementación de Diccionarios con **ABB**

- Para ello se utilizan los **AVL** (o árboles balanceados) que tienen en el peor caso (y en el promedio) igual complejidad que el caso promedio de los ABB, para las operaciones de diccionarios  $O(\log(n))$ .



# ABB - Análisis

Consideremos un AB (o ABB) completo:




$$n = 1 + 2^1 + 2^2 + \dots + 2^h = 2^{h+1} - 1$$

Luego, la **altura es  $O(\log_2 n)$**  en el caso de un árbol completo, pero  $O(n)$  de un árbol arbitrario. ¿Por qué?

¿Qué podemos concluir de este análisis sobre la eficiencia en tiempo de ejecución de las operaciones sobre un ABB?

# ABB - Análisis

**Insertar, Buscar y Borrar** tienen tiempo de ejecución proporcional a  $\log_2 n$  (siempre se recorre un sólo camino del árbol) si el árbol es completo pero, la eficiencia puede caer a orden  $n$  si el árbol se degenera (el caso extremo es una lista).





## ABB - Análisis


Si bien el orden de tiempo de ejecución promedio de las operaciones citadas para ABB's es  $O(\log_2 n)$ , el peor caso es  $O(n)$ .

La idea es entonces tratar de trabajar con ABB's que sean “completos”, o al menos que estén “balanceados”...

Tratando de refinar esta idea es que surgen los **AVL**

# Arboles AVL



- Un **árbol AVL** (Adelson-Velskii y Landis) es una ABB con una **condición de equilibrio**. Debe ser fácil mantener la condición de equilibrio, y ésta asegura que la profundidad del árbol es  **$O(\log(n))$** .
- **La condición AVL**: para cada nodo del árbol, la altura de los subárboles izquierdo y derecho puede diferir a lo más en 1 (hay que llevar y mantener la información de la altura de cada nodo, en el registro del nodo).



# Arboles AVL

- Así, todas las operaciones sobre árboles se pueden resolver en  $O(\log(n))$ , con la posible excepción de la inserción (si se usa eliminación perezosa - recomposición AVL tardía).

AVL Tree



## Arboles AVL (cont)

- Cuando se hace una **inserción** es necesario actualizar toda la información de equilibrio para los nodos en el camino a la raíz. La razón de que la inserción sea potencialmente difícil es que insertar un nodo puede violar la propiedad de árbol AVL.




ABB y **AVL**





ABB pero **no AVL**

# Arboles AVL: rotaciones

- Al **insertar** (según la inserción ABB) el 7 en el AVL anterior se viola la propiedad AVL para el nodo 9.
- Si éste es el caso, se tiene que restaurar la propiedad AVL antes de dar por culminado el proceso de inserción. Resulta que esto se puede hacer siempre con una modificación al árbol, conocida como **rotación** (simple y doble).

# Arboles AVL (cont)

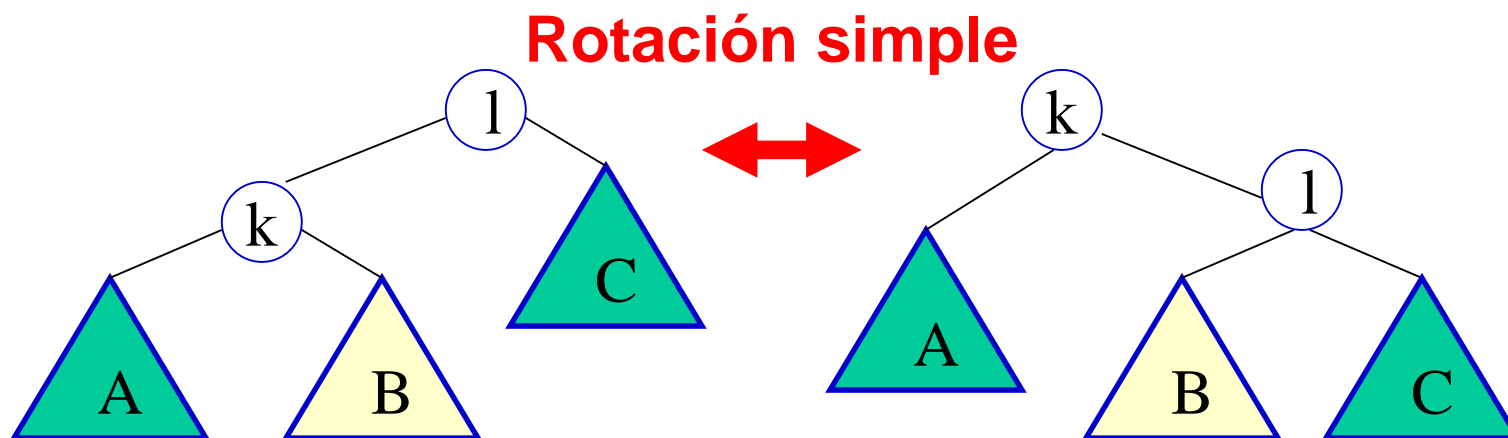


## Rotación simple



- Ambos son ABB's ?
- Qué implica una rotación con una implementación dinámica del árbol ?
- Qué punteros cambian ?
- Qué pasa con las alturas de los subárboles A, B y C ?
- Coinciden los recorridos In-order de ambos árboles ?

## Arboles AVL (cont)


- Insertar los elementos 1 al 7 a partir de un AVL vacío.




## Arboles AVL (cont)

- Inserción del 4 y luego del 5.

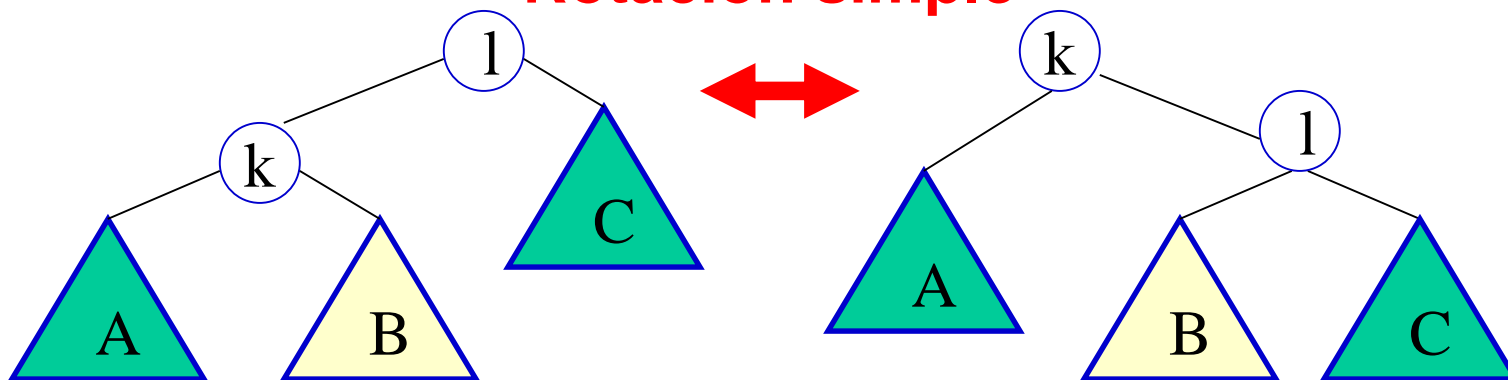
4)



5)




**Rotación simple**






## Arboles AVL (cont)

- Insertar los elementos 1 al 7 a partir de un AVL vacío.




### Rotación simple




# Arboles AVL (cont)

- Inserción del 7.

7)




**Rotación simple**



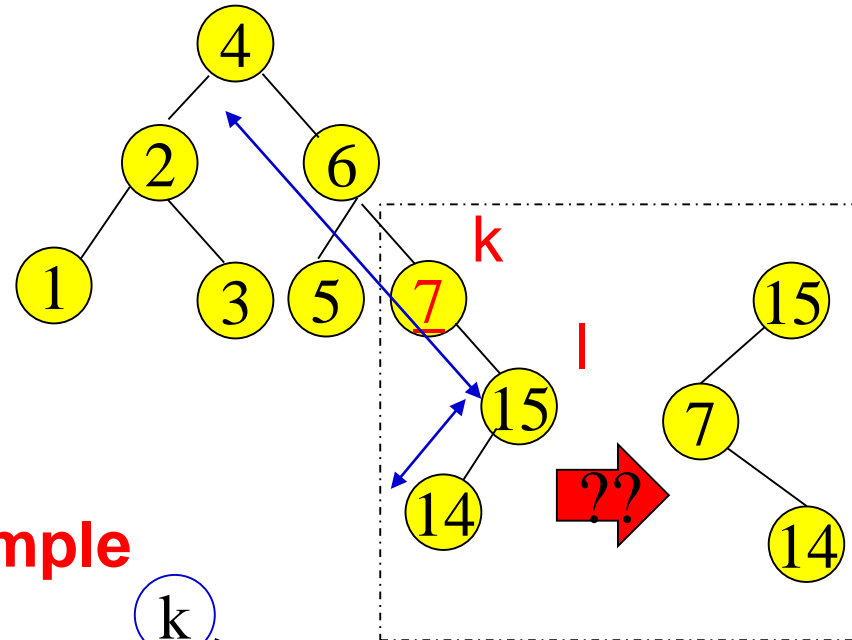
# Arboles AVL (cont)

- Ahora insertar los elementos del 15 al 12.


15)



14)




**Rotación simple**



## Arboles AVL (cont)



- Al insertar el 14, una rotación simple no recompone la propiedad AVL.
- Cuando el elemento insertado se encuentra entre los valores correspondientes a los nodos del árbol a rotar (por violación de la propiedad AVL), una rotación simple **no recompone** la propiedad AVL.
- Solución: usar una **rotación doble**, que involucra 4 subárboles en vez de 3.

# Arboles AVL: rotación doble





# Arboles AVL (cont)

- Inserción del 14.  
14)






# Arboles AVL (cont)

- Inserción del 13.  
13)




# Arboles AVL (cont)

- Inserción del 12.  
12)



**Rotación simple**





# Arboles AVL: inserción


## Algoritmo de inserción

insertar como en los ABB y luego iniciar en el nodo insertado y subir en el árbol, actualizando la información de equilibrio en cada nodo del camino. Acabamos si se llega a la raíz sin haber encontrado ningún nodo desequilibrado. Si no, se aplica una rotación (simple o doble, según corresponda) al primer nodo desequilibrado que se encuentre, se ajusta su equilibrio y ya está (no necesitamos llegar a la raíz, salvo que se use eliminación perezosa).

# Rebalanceando árboles AVL

Inserciones del tipo ABB que no conducen a un árbol AVL

– 4 casos




– 1 y 4 son similares

– 2 y 3 son similares

# Rebalanceando árboles AVL


Caso 1 solucionado por rotación simple



– Caso 4 es similar

# Rebalanceando árboles AVL

Caso 2 necesita una rotación *doble*



– Caso 3 es similar

# Arboles AVL: supresión

- **Algoritmo de supresión:** el algoritmo de eliminación que preserva la propiedad AVL para cada nodo del árbol es más complejo.  
En general, si las eliminaciones son relativamente poco frecuentes, puede utilizarse una estrategia de eliminación perezosa.
- La **pertenencia** es igual que para los ABB.
- Por más detalles y el código de las operaciones para una implementación de AVL con estructuras dinámicas ver el libro de Mark Allen Weiss.

# Ejercicios sobre ABB's y AVL's

Sugeridos:

Implementar el TAD Diccionario y el TAD Conjunto usando ABB's y AVL's.

Analizar la eficiencia en el peor caso y en el caso promedio para cada operación desarrollada.

# Hashing

## Operaciones relevantes en una colección (Conjunto/Set y Diccionario)

Consideremos las operaciones en un Set:

- Insertar (  $T\ x$ , Set &  $s$  )
- Borrar (  $T\ x$ , Set &  $s$  )
- Pertenece (  $T\ x$ , Set  $s$  )


Interesa particularmente la verificación de pertenencia de un elemento.

# Hashing


## Representaciones

Algunas alternativas conocidas mencionadas:

- Listas encadenadas.
- Árboles binarios de búsqueda.



$\log(N)$   
comparaciones  
*en promedio*





## Arreglo de booleanos / bits

Sea  $S$  un set implementado con un arreglo de booleanos, y  $s$  un array de  $N$  elementos booleanos. Se define a  $s[n]$  como verdadero si y solo si  $\text{Pertenece}(n, S)$ .

0	1	2	3	4	5
1	1	0	1	0	0

$s[0] = \text{true} \rightarrow 0 \in S$

$s[1] = \text{true} \rightarrow 1 \in S$

$s[2] = \text{false} \rightarrow 2 \notin S$

$s[3] = \text{true} \rightarrow 3 \in S$

$s[4] = \text{false} \rightarrow 4 \notin S$

$s[5] = \text{false} \rightarrow 5 \notin S$

# Tipos y rangos de datos

El arreglo de booleanos permite determinar la pertenencia con una sola operación. Insertar, Borrar y Pertenece tienen  $O(1)$  peor caso.


Soporta únicamente datos numéricos (en un subrango de los naturales).

El rango de los elementos puede ser un impedimento para esta técnica, por el alto requerimiento de memoria.

# Noción de hash

Consiste en:

- Array de  $M$  elementos conocidos como “buckets” (tabla de hash).
- Función  $h$  de dispersión sobre las claves.
- Estrategia de resolución de colisiones.



# Función de hash

Propiedades imprescindibles:

- Dependiente únicamente de la clave
- Fácil de computar (rápida)
- Debe minimizar las colisiones

Su diseño depende fuertemente de la naturaleza del espacio de claves. Se busca que la función distribuya uniformemente.

Algunas funciones utilizadas comúnmente:  
división, *middle square*, polinomial

## Método de división

Se define la función  $h$  según  $h(k) = k \bmod M$ , donde  $M$  es el tamaño de la tabla y  $\bmod$  es el resto de la división entera (%).

Se recomienda que  $M$  sea un número primo.

Valores consecutivos de claves  $k$  producen buckets adyacentes en el hash, lo cual no siempre es deseable.

## Para cadenas (strings)

Por lo general las claves (o los elementos) son números o cadenas de caracteres.

En este último caso, una opción es sumar los valores ASCII de los caracteres de la cadena y retornar la suma módulo  $M$  (tamaño de la tabla). No obstante, la función no distribuye bien las claves si el tamaño de la tabla es grande. Ejemplo:  $M=10007$  y  $\text{longitud}(x) \leq 8$ .  $h(x) \in [0..1016]$  ( $1016=127*8$ ).

## Para cadenas (strings)

En el libro de Weiss (cap.5) hay más ejemplos de funciones de hash, como por ejemplo: la función que calcula  $h(k) = k_1 + c \cdot k_2 + c^2 \cdot k_3 + \dots \bmod M$  (con  $c$  una constante (ej. 32)) y  $k_i$  el código ASCII del  $i$ -ésimo carácter de la cadena  $k$ .

Importante: Se sugiere usar tablas de un tamaño proporcional a la cantidad esperada de elementos y que este tamaño sea un número primo.

# Colisiones

Ninguna función de hash puede garantizar que la estructura está libre de colisiones.

Toda implementación de hash debe proveer una estrategia para su resolución.

Estrategias más comunes:

- Separate chaining (*hashing* abierto)
- Linear probing (*hashing* cerrado)
- Double hashing




# Separate chaining

## Hasing Abierto

Las colisiones resultan en un nuevo nodo agregado en el bucket.

Las listas en promedio tienen largo acotado.

La verificación de pertenencia de  $k$  implica buscar en la lista del bucket  $h(k)$ .



# Separate chaining




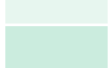
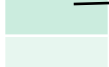


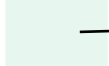


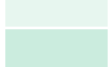


## Hasing Abierto

Ejemplo:

- $M=13$
- $\text{hash: int} \rightarrow \text{int}, \text{hash}(x) = x \% M$

Insertar:


3, 0, 7, 16, 11, 26, 10, 40, 12,  
131, 1308, 265, 15 ...

Tabla		
0		→ [0,26,...]
1		→ [40,131...]
2		→ [15,...]
3		→ [3,16,...]
4		→ [...]
5		→ [265,...]
6		→ [...]
7		→ [7,...]
8		→ [1308,...]
9		→ [...]
10		→ [10,...]
11		→ [11,...]
12		→ [12,...]

# Linear probing

## Ejemplo de Hashing Cerrado

Dada una clave  $k$ , la secuencia de prueba hasta encontrar un lugar libre en una tabla de tamaño  $M$  es  $h_i(k) = (h(k) + i) \bmod M$  con  $i \in [0, M-1]$ .



# Factor de Carga

El factor de carga (FC) es  $N/M$  (N es el número de elementos en la tabla y M el tamaño de ésta). La longitud media de una lista en hashing abierto es FC.

El esfuerzo requerido para una búsqueda es el tiempo que hace falta para evaluar la función de hash más el tiempo necesario para evaluar la lista.

## Factor de Carga

En una búsqueda infructuosa el nro promedio de enlaces por recorrer es FC.

En una búsqueda exitosa, el nro es  $FC / 2$ .

Este análisis demuestra que el tamaño de la tabla no es realmente importante, pero el factor de carga sí lo es.

La regla general en open hashing es hacer el tamaño de la tabla casi tan grande como el nro de elementos esperados ( $FC \cong 1$ ) y elegir a M un nro primo.

## Tiempo promedio y peor caso

**$O(1)$  promedio:** Hashing utiliza tiempo constante por operación, en promedio, y no existe la exigencia de que los conjuntos sean subconjuntos de algún conjunto universal finito (como en los arreglos de booleanos). *El FC y la función de hash son factores claves.*

**$O(n)$  peor caso:** En el peor caso este método requiere, para cada operación, un tiempo proporcional al tamaño del conjunto, como sucede con realizaciones con listas encadenadas y arreglos.

# Hashing

## Ejercicios

Implementar el TAD Diccionario usando:

- *Listas no ordenadas; listas ordenadas; arreglos de booleanos/bits; arreglos con tope.*
- *open hashing, considerando que existe un número esperado  $M$  de elementos de tipo *int* y que todos son igualmente probables. Si el tipo de los elementos es de tipo *string*, pero se mantienen las mismas condiciones, ¿qué cambia en la implementación realizada?*
- *Analizar ventajas y desventajas de las implementaciones anteriores, incluyendo eficiencia en tiempo y espacio.*

# Multisets



## Un TAD Multiset

- **Vacio**  $m$ : construye el multiset  $m$  vacío;
- **Insertar  $x$   $m$ : agrega  $x$  a  $m$ ;**
- **EsVacio**  $m$ : retorna true si y sólo si el multiset  $m$  está vacío;
- **Ocurrencias**  $x$   $m$ : retorna la cantidad de veces que está  $x$  en  $m$ ;
- **Borrar**  $x$   $m$ : elimina una ocurrencia de  $x$  en  $m$ , si  $x$  está en  $m$ ;
- **Destruir**  $m$ : destruye el multiset  $m$ , liberando su memoria.

# Ejercicios

¿Cómo se pueden adaptar las implementaciones de Sets (Conjuntos) a *multisets*?

- Especificar el TAD Multiset en C++.
- Adaptar y analizar para *multisets* las siguientes implementaciones vistas para conjuntos:
  - Variantes de Listas
  - Arreglos de Booleanos (ahora...)
  - ABBs

Notar que un multiset se puede ver como un set de pares de elementos:  $(e_i, \#e_i)$ .

## Ejercicios (cont)

- Adaptar y analizar para *multisets* las siguientes implementaciones vistas para conjuntos:

- Variantes de Listas


→  $e_1 \rightarrow e_2 \rightarrow e_1 \rightarrow \dots$

→  $e_1, \#e_1 \rightarrow e_2, \#e_2 \rightarrow \dots$

- Arreglos de Booleanos (ahora...)



- ABBs



# **Tablas o Funciones Parciales (Mappings)**

# El TAD Tabla (Mapping, Table)

Una **tabla** es una **función parcial** de elementos de un tipo, llamado el tipo dominio, a elementos de otro (posiblemente el mismo) tipo, llamado el tipo recorrido o rango.

Que una tabla  $T$  asocie el elemento  $r$  del recorrido al elemento  $d$  del dominio lo denotaremos  $T(d) = r$ .

Existen funciones, como  $\text{cuadrado}(i) = i^2$ , que pueden ser fácilmente implementadas como una función de C++ que implementa la expresión que computa la función. Sin embargo, **para muchas funciones no existe otra forma de describir  $T(d)$  más que almacenar para cada  $d$  el valor  $T(d)$ .**

# El TAD Tabla (Mapping, Table)

Ejemplo: implementar una función que asocie a cada estudiante el conjunto de asignaturas de la carrera que tiene aprobadas.

Otro ejemplo: para aplicar una función de nómina que asocie a cada empleado un salario semanal, es necesario almacenar el salario actual de cada empleado (si no hay una regla general).

Veamos cuáles son las operaciones que definen a este tipo abstracto.

Dado un elemento  $d$  del dominio nos interesa **recuperar** el elemento  $T(d)$  o saber si  $T(d)$  **está definido** (si  $d$  pertenece al dominio de  $T$ ).

## El TAD Tabla (Mapping, Table)

También nos interesa **dar de alta** elementos en el dominio de  $T$  y **almacenar** sus correspondientes valores.

Alternativamente, también nos interesa **modificar el valor  $T(d)$**  para un determinado  $d$ .

Finalmente, necesitamos una operación que nos permita construir una **tabla vacía**, es decir, la tabla cuyo dominio es vacío.

# TAD Tabla/Mapping. Operaciones para:

- construir una tabla vacía;
- insertar una correspondencia  $(d,r)$  en una tabla  $t$ . Si  $d$  está definida en  $t$  (tiene imagen), actualiza su correspondencia con  $r$ ;
- saber si una tabla está vacía;
- saber si un valor  $d$  tiene imagen en una tabla  $t$ ;
- obtener la imagen de un valor  $d$  en una tabla  $t$ ;
- eliminar una correspondencia de una tabla.
- destruir una tabla.



# Implementación del TAD Tabla (Mapping, Table)

Existen muchas posibles implementaciones de tablas con dominios finitos. Una de las implementaciones más utilizadas es por medio de tablas de Hashing.

Es posible que el tipo dominio de una tabla sea un tipo elemental de C/C++ y por lo tanto pueda ser usado como el tipo índice de un arreglo. En este caso, la tabla puede ser implementada directamente como un arreglo.

# Implementación del TAD Tabla (Mapping, Table)

En general, cualquier tabla con dominio finito puede ser representada como una **lista de pares**  $(d_1, r_1)$ ,  $(d_2, r_2)$ , ...,  $(d_k, r_k)$  donde los  $d_i$  son los elementos corrientes del dominio y  $r_i$  es el valor que la tabla asocia con  $d_i$ , para  $i = 1..k$ .

Nuevamente, si el dominio de la tabla admite un orden total, también es una alternativa de implementación razonable usar **ABB (o AVL)**.

# Implementación del TAD Tabla (Mapping, Table)

En una implementación con arreglos, deberíamos considerar un valor mínimo  $\text{minD}$  y un valor máximo  $\text{maxD}$  para el dominio.

## Ejercicios:


- Especificar el TAD Tabla (*mapping*).
- Discutir, desarrollar y analizar todas las implementaciones vistas previamente, ahora para *tablas (mappings)*: Listas, Arreglos de Booleanos?, ABBs, Arreglos con tope, Hashing.

Notar que un *mapping* se puede ver como un conjunto de pares: Dominio - Rango:  $(d, r)$ .


## Ejercicios (cont)

- Adaptar y analizar para *mappings* las siguientes implementaciones vistas para conjuntos:


- Listas



- Arreglos de Booleanos (ahora...)



- ABBs



## Ejercicios (cont)

- Adaptar y analizar para *mappings* las siguientes implementaciones vistas para conjuntos:
  - Arreglos con tope de pares  $(d,r)$  ordenado por dominio

$< \text{Dominio}$



- Hashing abierto

hash: Dominio  $\rightarrow$  int

